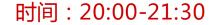




第17期Spark亚太研究院 决胜大数据时代公益大讲堂

--在线讲座



环节1:内容分享

环节2:自由问答

本期土题。源码彻底解析Shuffle的前世今生和来世

Topic 1:Shuffle的工作机制

Topic 2: Shuffle操作

Topic 3:深度解析Shuffle的read和write



王老师,Spark亚太研究院院长和首席专家;目前中国唯一的移动互联网和云计算大数据集大成者,在完成了对Spark源码的彻底研究的同时不断在实际环境中使用Spark的各种特性的基础之上,编写了世界上第一本系统性的Spark书籍并开设了世界上第一个系统性的Spark课程。

Spark亚太研究院: <u>www.sparkinchina.com</u> QQ交流群: 317540673 (已满)、297931500 微信公众号:spark-china



2014 Spark 亚太峰会 Spark Asia-pacific Summit 2014

从技术走向视野

From Technology to Solutions

2014年 12月 6-7日 北京珠三角万豪酒店

2014 年亚太地区规格最高的 Spark 技术盛会!

面向大数据、云计算开发者、技术爱好者的饕餮盛宴!

云集国内外 Spark 技术领军人物及灵魂人物!

技术交流、应用分享、源码研究、商业案例探询!

Spark亚太峰会详情: http://www.sparkinchina.com/meeting/2014yt/default.asp



2014年9月30日—12月3日

- ▶ 如果你是对Spark有浓厚兴趣的初学者,在这里你会有绝佳的入门和实践机会!
- > 如果你是Spark的应用高手,在这里以"武"会友,和技术大牛们尽情切磋!
- ▶ 如果你是对Spark有深入独特见解的专家,在这里可以尽情展现你的才华!

无论你是谁、只要对Spark有兴趣,还在等什么,快来参加!

Spark开发者大赛,在这里会让你受益匪浅!

Spark开发者大赛详情: http://www.sparkinchina.com/meeting/2014yt/dhhd.asp





国内第一个Spark系列课程 《大数据Spark实战之路》

重磅上线

第一阶段:熟练的掌握Scala语言

学习地址: http://edu.51cto.com/pack/view/id-124.html

第二阶段:精通Spark平台本身提供给开发者API

学习地址: http://edu.51cto.com/pack/view/id-146.html

第三阶段:精通Spark内核

学习地址: http://edu.51cto.com/pack/view/id-148.html

第四阶段:掌握基于Spark上的核心框架的使用

学习地址: http://edu.51cto.com/pack/view/id-149.html

第五阶段:商业级别大数据中心黄金组合:Hadoop + Spark

学习地址: http://edu.51cto.com/pack/view/id-150.html

第六阶段:Spark源码完整解析和系统定制

学习地址: http://edu.51cto.com/pack/view/id-151.html





Spark官方文档中文翻译 正式发布!

感谢Spark官方文档中文翻译团成员! (排名不分先后)

傅智勇、吴洪泽、武扬、徐骄、蔡立宇、harli、吴卓华、樊登贵、韩保礼、颜军、Jack Niu、俞杭军、唐海东、刘亚卿、耿元振、王庆刚、徐敬丽



Spark专刊书籍 即将发布

由专刊编写人员进行编写的 第一本Spark专刊!

业界第一本Spark专刊

借助于Spark亚太研究院社区的力量编写而成深度揭秘大数据时代统一的计算平台Spark



Spark业界使用报告、Spark生态系统、Spark架构设计、Spark内核实现、实时计算、机器学习、图计算、Shark、Shark、

Spark SQL、
Spark on Yarn、
JobServer、
Spark多语言编程、
企业大数据中心的构建
最佳实践
Spark学习最佳路径



国内第一本Spark书籍连载首发 每周一个章节51CTO下载频道连载

- ✓图文并茂,边学习,边演练
- ✓不需要任何前置知识,
- ✓从零开始,循序渐进

书籍下载: http://down.51cto.com/zt/6876

本周更新更新到第5章Spark API编程动手实战(4)

Life is short, you need Spark!



从零开始

不需要任何基础、带领你无痛人(1 Spork

云计算分布式大数据 Spark 实战高手之路

王家林荟

Spark 亚太研究院系列丛书 版权所



51CTO.com 技术成就發想

年度推荐图书

通过近30个动手实践的案例,循序渐进的展示Spark GraphX框架方方面面的功能和使用方法,同时伴随Spark GraphX恰到要害的源码解析,是图计算爱好者和Spark学习者不可错过的饕餮盛宴!



Spark GraphX大规模图计算和图挖掘

Spark亚太研究院 王家林著

好书来袭! 重磅推出! Spark GraphX 大规模图计算和图挖掘(V3.0)

近30个动手实践案例,循序渐进展示 Spark GraphX框架方方面面的功能和使用方法,同时伴随Spar k GraphX源码解析,是图计算爱好者和Spark学习者不可错过的饕餮盛宴!

在线阅读地址:

http://book.51cto.com/art/201408/450049.htm

下载地址:

http://down.51cto.com/data/1881041



最新线下公开课

决胜大数据时代: Hadoop、Yarn、Spark企业级最佳实践

✓10月26—28日 北京

✓11月01—03日 深圳

聚焦大数据领域三项核心技术(
既解决当下问题,又有助于驾驭未来)



Spark亚太研究院 微信二维码

微信公众号: spark-china

精彩 不容错过

Spark亚太研究院: <u>www.sparkinchina.com</u> QQ交流群: 1群:317540673(已满)2群: 297931500



10月23日第18期Spark亚太研究院决胜大数据时代公益大讲堂

主题:源码彻底解析Standalone的前世今生和来世

报名方式:

- 1、Spark亚太研究院QQ群: 317540673(已满)、 297931500
- 2、51CTO学院推荐课程(报名地址: 51CTO首页-视频学院--搜索 "Spark亚太研究院决胜大数据时代100期公益大讲堂"点击报名)
- 3、点击群公告报名
- 4、拨打4006-998-758电话报名



第19期公益大讲堂课程内容投票

- A、源码解析Spark on Yarn的内幕
- B、源码彻底解析Cache和CheckPoint的前世今生和来世
- C、源码解析Spark Storage模块
- D、源码彻底解析Tachyon
- E、源码彻底解析Driver的前世令生和来世
- F、源码彻底解析Master的前世今生和来世
- G、源码彻底解析Worker的前世今生和来世



请在群应用投票中进行投票





4006-998-758

Spark亚太研究院: www.sparkinchina.com QQ交流群: 317540673(已满)、 297931500





Spark亚太研究院: <u>www.sparkinchina.com</u> QQ交流群: 317540673(已满)、297931500

Spark打破Hadoop排序刷新时间记录



To evaluate these improvements, we decided to participate in the Sort Benchmark. With help from Amazon Web Services, we participated in the Daytona Gray catesory, an industry benchmark on how fast a system can sort 100 TB of data (1 trillion records). Although our entry is still under review, we are eager to share with you our submission. The previous world record was 72 minutes, set by Yahoo using a Hadoop MapReduce cluster of 2100 nodes Psing Spark on 206 EC2 nodes, we completed the benchmark in 23 minutes. This means that Spark sorted the same wata 3X faster using 10X fewer machines. All the sorting took place on disk (HDFS), without using Spark's in-memory cache.

Spark打破Hadoop排序刷新时间记录 型表



Additionally, while no official petabyte (PB) sort competition exists, we pushed Spark further to also sort 1 PB of data (10 trillion records) on 190 machines in under 4 hours. This PB time beats previously reported results based on Hadoop MapReduce (16 hours on 3800 machines). To the best of our knowledge, this is the first petabyte-scale sort ever done in a public cloud.

Spark打破Hadoop排序刷新时间记录 ^工亚太研究院



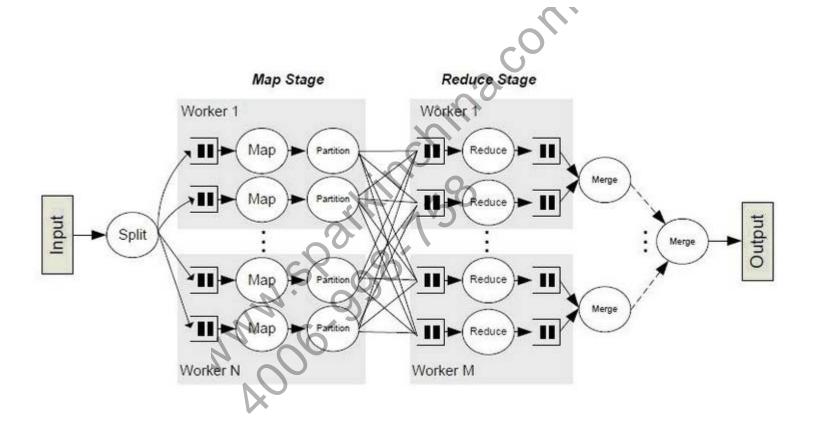


	Hadoop World Record	Spark 100 TB *	Spark 1 PB
Data Size	102. 5 TB	100 TB	1000 TB
Elapsed Time	72 mins	28 mins	234 mins
# Nodes	2100	206	190
# Cores	50400	6592	6080
# Reducers	10,000	29, 000	250,000
Rate	1.42 TB/min	4.27 TB/min	4.27 TB/min
Rate/node	0.67 GB/min	20.7 GB/min	22.5 GB/min
Sort Benchmark Daytona Rules	Yes	Yes	No
Environment	dedicated data	EC2 (i2.8xlarge)	EC2 (i2.8xlarge)

MapReduce Shuffle



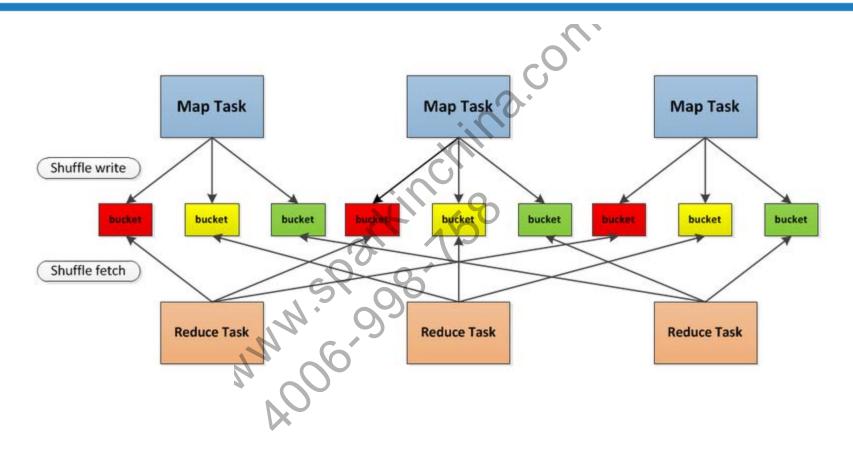




Spark Shuffle



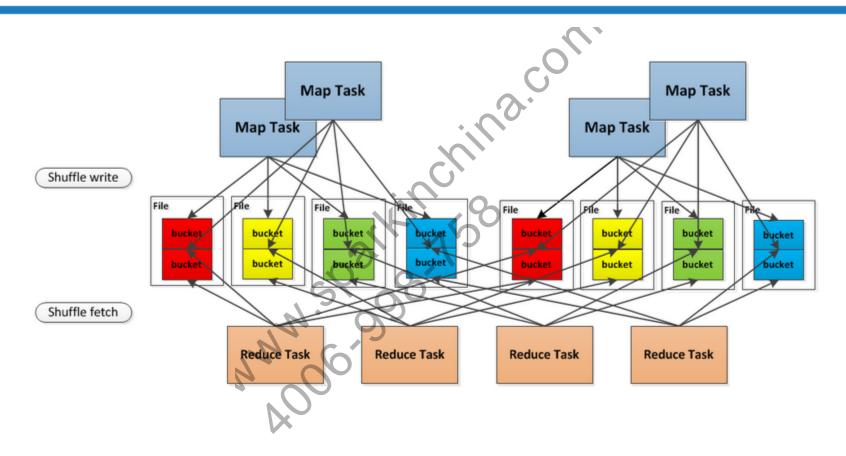




Shuffle Consolidation



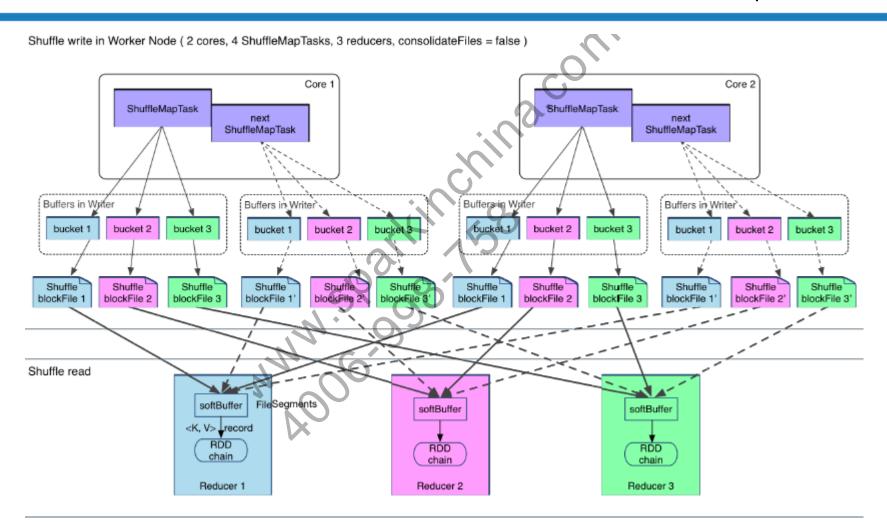




Shuffle Write



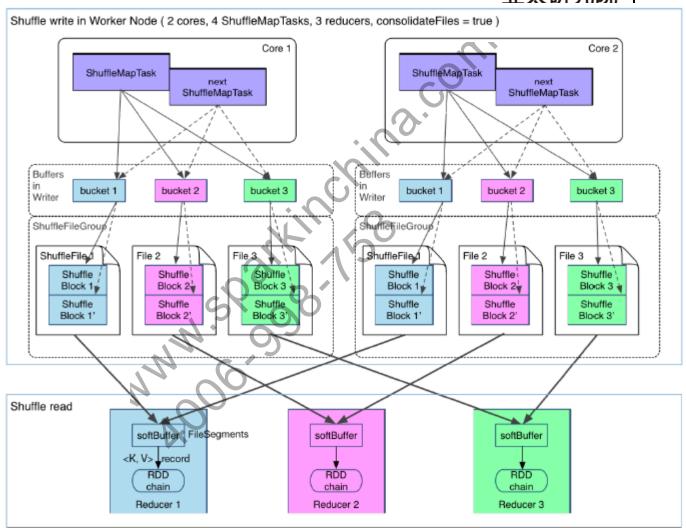




Shuffle Write

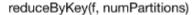


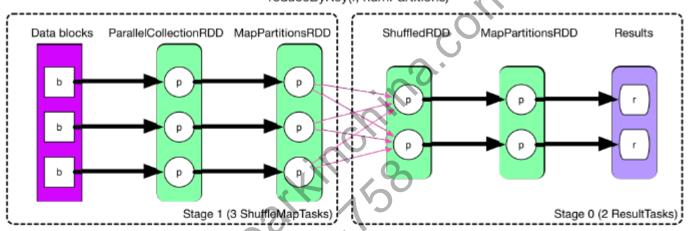




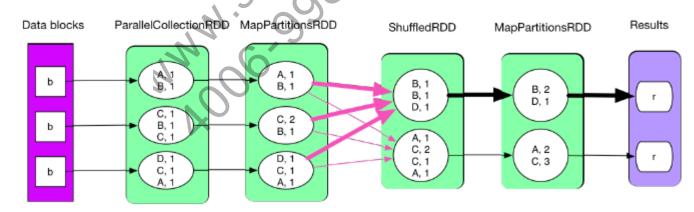




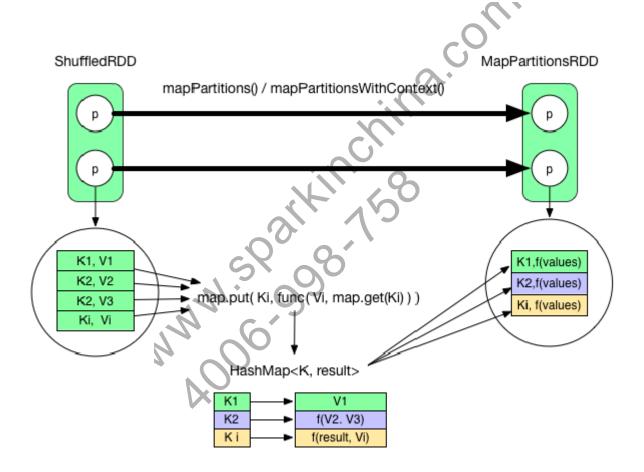




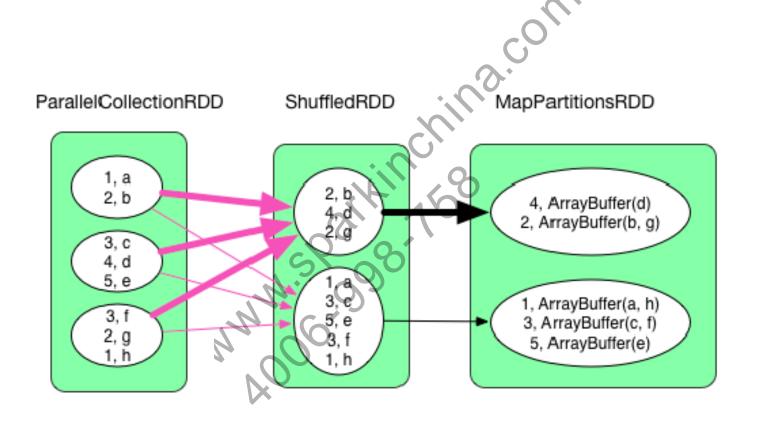
Example (WordCount): reduceByKey(_ + _, 2)



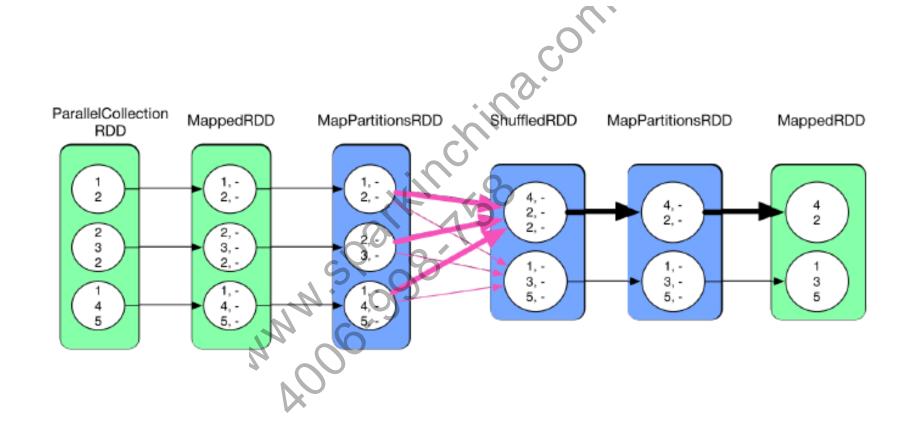




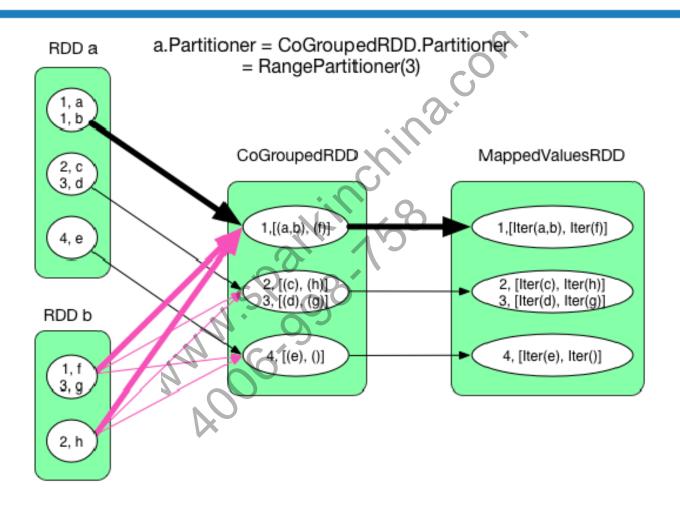








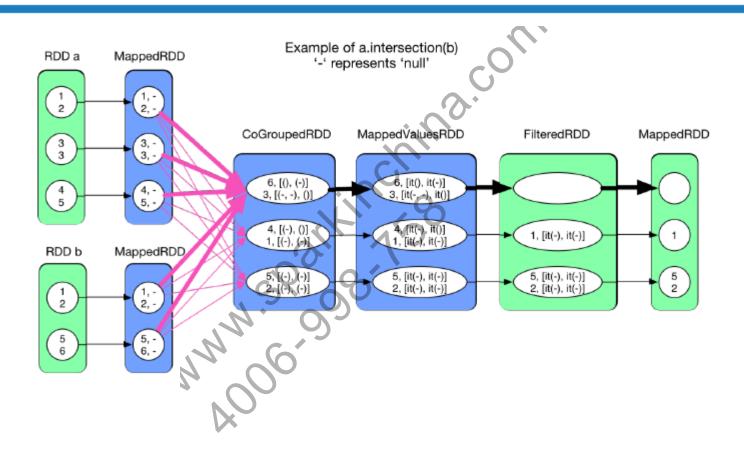




典型的Shuffle: intersection



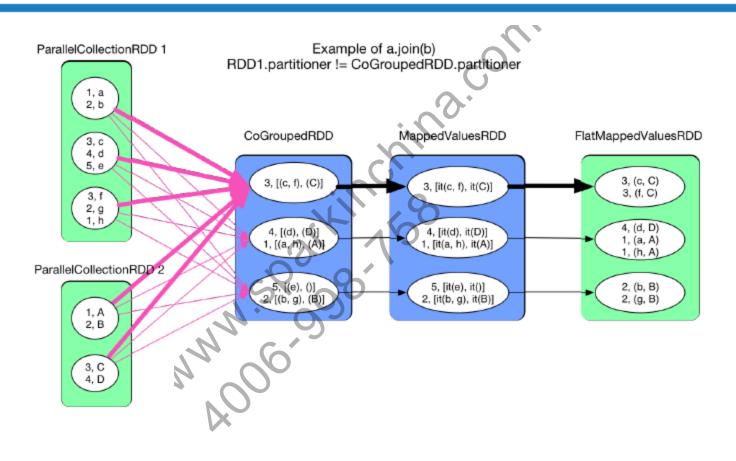




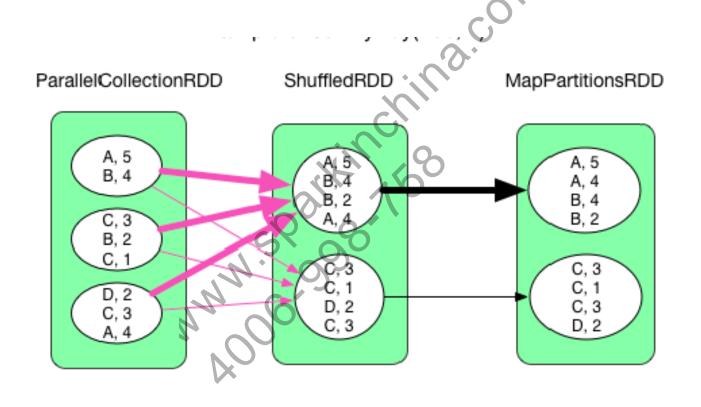
典型的Shuffle: join



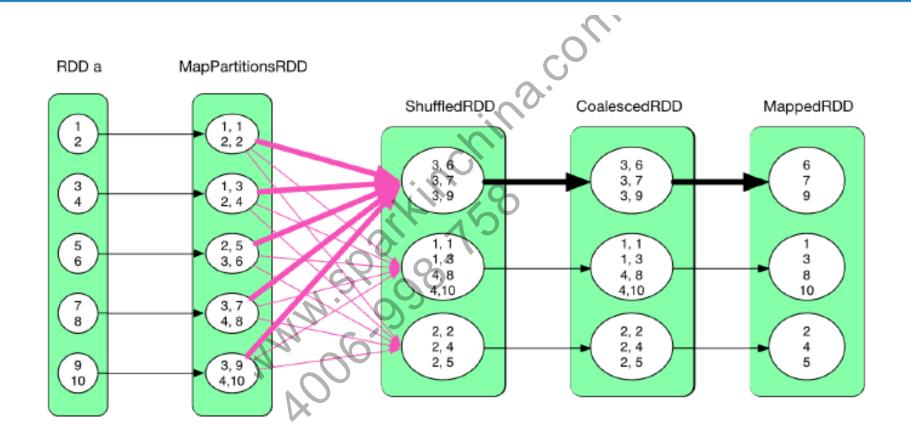








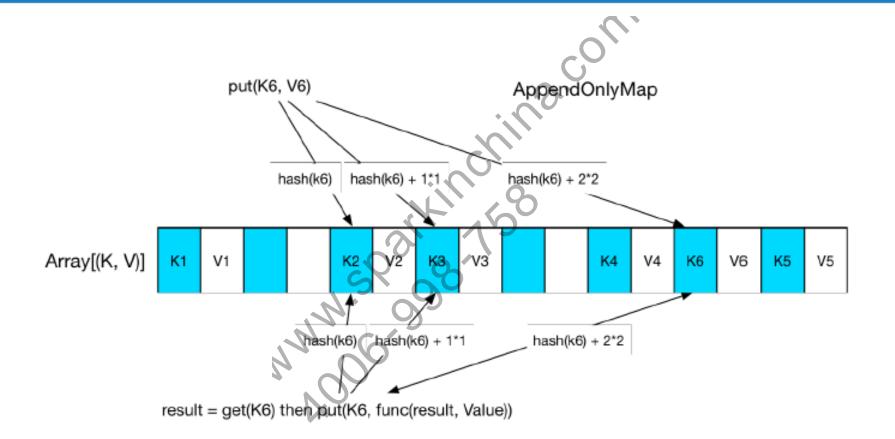




AppendOnlyMap



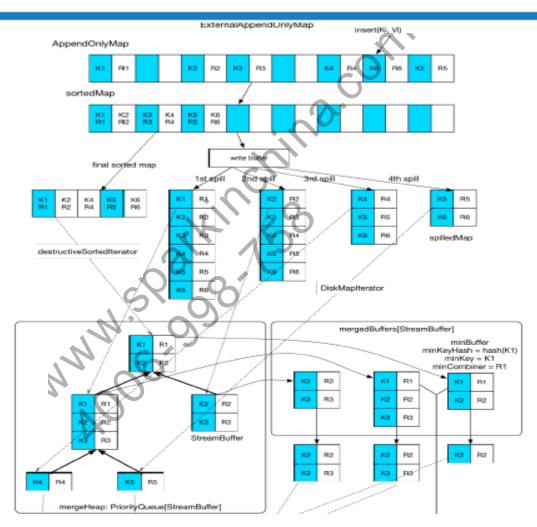




ExternalAppendOnlyMap



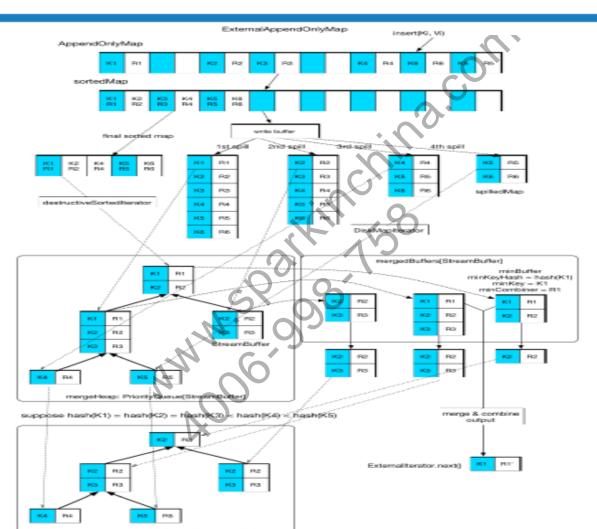




ExternalAppendOnlyMap









2014 Spark 亚太峰会 Spark Asia-pacific Summit 2014

从技术走向视野

From Technology to Solutions

2014年 12月 6-7日 北京珠三角万豪酒店

2014 年亚太地区规格最高的 Spark 技术盛会!

面向大数据、云计算开发者、技术爱好者的饕餮盛宴!

云集国内外 Spark 技术领军人物及灵魂人物!

技术交流、应用分享、源码研究、商业案例探询!

Spark亚太峰会详情: http://www.sparkinchina.com/meeting/2014yt/default.asp



2014年9月30日—12月3日

- ▶ 如果你是对Spark有浓厚兴趣的初学者,在这里你会有绝佳的入门和实践机会!
- > 如果你是Spark的应用高手,在这里以"武"会友,和技术大牛们尽情切磋!
- ▶ 如果你是对Spark有深入独特见解的专家,在这里可以尽情展现你的才华!

无论你是谁、只要对Spark有兴趣,还在等什么,快来参加!

Spark开发者大赛,在这里会让你受益匪浅!

Spark开发者大赛详情: http://www.sparkinchina.com/meeting/2014yt/dhhd.asp





国内第一个Spark系列课程 《大数据Spark实战之路》

重磅上线

第一阶段:熟练的掌握Scala语言

学习地址: http://edu.51cto.com/pack/view/id-124.html

第二阶段:精通Spark平台本身提供给开发者API

学习地址: http://edu.51cto.com/pack/view/id-146.html

第三阶段:精通Spark内核

学习地址: http://edu.51cto.com/pack/view/id-148.html

第四阶段:掌握基于Spark上的核心框架的使用

学习地址: http://edu.51cto.com/pack/view/id-149.html

第五阶段:商业级别大数据中心黄金组合:Hadoop + Spark

学习地址: http://edu.51cto.com/pack/view/id-150.html

第六阶段:Spark源码完整解析和系统定制

学习地址: http://edu.51cto.com/pack/view/id-151.html





Spark官方文档中文翻译 正式发布!

感谢Spark官方文档中文翻译团成员! (排名不分先后)

傅智勇、吴洪泽、武扬、徐骄、蔡立宇、harli、吴卓华、樊登贵、韩保礼、颜军、Jack Niu、俞杭军、唐海东、刘亚卿、耿元振、王庆刚、徐敬丽



Spark官方文档翻译 即将发布

由专刊编写人员进行编写的 第一本Spark专刊!

业界第一本Spark专刊

借助于Spark亚太研究院社区的力量编写而成深度揭秘大数据时代统一的计算平台Spark



Spark业界使用报告、 Spark生态系统、 Spark架构设计、 Spark内核实现、 实时计算、 机器学习、 图计算、 Shark、 Spark SQL、
Spark on Yarn、
JobServer、
Spark多语言编程、
企业大数据中心的构建
最佳实践
Spark学习最佳路径



国内第一本Spark书籍连载首发 每周一个章节51CTO下载频道连载

- ✓图文并茂,边学习,边演练
- ✓不需要任何前置知识,
- ✓从零开始,循序渐进

书籍下载: http://down.51cto.com/zt/6876

本周更新更新到第5章Spark API编程动手实战(4)

Life is short, you need Spark!



从零开始

不需要任何基础、带领你无痛人(1 Spork

云计算分布式大数据 Spark 实战高手之路

王家林荟

Spark 亚太研究院系列丛书 版权所



51CTO.com 技术成就梦想

年度推荐图书

通过近30个动手实践的案例,循序渐进的展示Spark GraphX框架方方面面的功能和使用方法,同时伴随Spark GraphX恰到要害的源码解析,是图计算爱好者和Spark学习者不可错过的饕養盛宴!



Spark GraphX大规模图计算和图挖掘

Spark亚太研究院 王家林著

好书来袭! 重磅推出! Spark GraphX 大规模图计算和图挖掘(V3.0)

近30个动手实践案例,循序渐进展示 Spark GraphX框架方方面面的功能和使用方法,同时伴随Spar kGraphX源码解析,是图计算爱好者和Spark学习者不可错过的饕餮盛宴!

在线阅读地址:

http://book.51cto.com/art/201408/450049.htm

下载地址:

http://down.51cto.com/data/1881041



最新线下公开课

决胜大数据时代: Hadoop、Yarn、Spark企业级最佳实践

✓10月26—28日 北京

✓11月01—03日 深圳

聚焦大数据领域三项核心技术(
既解决当下问题,又有助于驾驭未来)



Spark亚太研究院 微信二维码

微信公众号: spark-china

精彩 不容错过

Spark亚太研究院: <u>www.sparkinchina.com</u> QQ交流群: 1群:317540673(已满)2群: 297931500



10月23日第18期Spark亚太研究院决胜大数据时代公益大讲堂

主题:源码彻底解析Standalone的前世今生和来世

报名方式:

- 1、Spark亚太研究院QQ群: 317540673(已满)、 297931500
- 2、51CTO学院推荐课程(报名地址: 51CTO首页-视频学院--搜索 "Spark亚太研究院决胜大数据时代100期公益大讲堂"点击报名)
- 3、点击群公告报名
- 4、拨打4006-998-758电话报名



第19期公益大讲堂课程内容投票

- A、源码解析Spark on Yarn的内幕
- B、源码彻底解析Cache和CheckPoint的前世今生和来世
- C、源码解析Spark Storage模块
- D、源码彻底解析Tachyon
- E、源码彻底解析Driver的前世令生和来世
- F、源码彻底解析Master的前世今生和来世
- G、源码彻底解析Worker的前世今生和来世



请在群应用投票中进行投票





4006-998-758

Spark亚太研究院: www.sparkinchina.com QQ交流群: 317540673(已满)、 297931500





Spark亚太研究院: <u>www.sparkinchina.com</u> QQ交流群: 317540673(已满)、297931500